

TP INDIVIDUEL S2

Étape KDD	Action concrète (1-2 phrases)	Problème potentiel	Outil Python
1. Data Integration	Regrouper les données provenant de différentes sources (fichiers CSV, Excel ou bases de données) dans un seul ensemble cohérent.	Doublons, formats incompatibles, données contradictoires.	pandas (pd.concat(), pd.merge())
2. Data Selection	Sélectionner uniquement les colonnes utiles à l'analyse, par exemple Produit, Quantité, Prix, Date et Région.	Colonnes non pertinentes ou données insuffisantes.	pandas (loc, filter)
3. Data Cleaning	Détecter et corriger les valeurs manquantes, les doublons et les erreurs de saisie.	Valeurs nulles, incohérences, données bruitées.	pandas (dropna(), fillna(), drop_duplicates())
4. Data Transformation	Convertir les données dans un format adapté à l'analyse (normalisation, encodage, agrégation).	Formats incompatibles ou variables mal représentées.	pandas, NumPy, scikit-learn
5. Data Mining	Appliquer des techniques d'analyse pour découvrir des modèles ou tendances dans les ventes.	Mauvais choix d'algorithme ou surapprentissage.	scikit-learn (KMeans, DecisionTree, etc.)
6. Pattern Evaluation	Évaluer la pertinence des résultats obtenus à l'aide de métriques statistiques ou visuelles.	Résultats peu significatifs ou difficiles à interpréter.	scikit-learn, matplotlib, seaborn
7. Knowledge Presentation	Présenter les résultats sous forme de graphiques, tableaux ou rapports afin de faciliter la prise de décision.	Mauvaise visualisation ou interprétation erronée.	matplotlib, seaborn, pandas