

TP Individuel – Fouille des Données

Cas 1

Situation

Orange Guinée analyse 5 ans de logs d'appels (500 Go) pour détecter des fraudes SIM en temps réel.

Approche

Big Data + Machine Learning

Justification

Le volume des données est très grand (500 Go), donc une technologie Big Data est nécessaire pour stocker et traiter les informations rapidement.

La détection de fraude en temps réel utilise aussi le Machine Learning afin d'identifier automatiquement des comportements suspects à partir des données des appels.

Outil : Apache Spark

Cas 2

Situation

Une banque guinéenne de microfinance prédit si un demandeur de crédit va rembourser ou non.

Approche

Machine Learning

Justification

Ce problème consiste à faire une prédiction à partir des anciennes données des clients.

Le Machine Learning permet d'entraîner un modèle capable de classer les demandeurs en deux catégories : bon payeur ou mauvais payeur.

Outil : Scikit-Learn

Cas 3

Situation

Un hôpital de Conakry regroupe des patients en profils similaires SANS diagnostic préalable.

Approche

Data Mining

Justification

Le regroupement des patients sans connaître les catégories à l'avance correspond à une technique de clustering.

La fouille de données permet de découvrir automatiquement des groupes similaires dans les données médicales.

Outil : Weka